

```
import pandas as pd
import numpy as np
```

La groupby si utilizza quando abbiamo a che fare con una variabile categorica e una continua.
Ad esempio, se abbiamo una variabile categorica A A B A C B A, e una continua 3,21,10,4,65,33,26, possiamo raggruppare
in base ad un canone scelto per la variabile continua. Ad esempio, se volessimo conoscere la somma della variabile continua
rispetto alla variabile categorica, otterremo: variabile categorica: A B C variabile continua: Boh sti cavoli
tanto il concetto è chiaro

```
mpg = pd.read_csv("mpg.csv")
mpg
```

	mpg	cylinders	displacement	horsepower	weight	acceleration	\
0	18.0	8	307.0	130	3504	12.0	
1	15.0	8	350.0	165	3693	11.5	
2	18.0	8	318.0	150	3436	11.0	
3	16.0	8	304.0	150	3433	12.0	
4	17.0	8	302.0	140	3449	10.5	
..	
393	27.0	4	140.0	86	2790	15.6	
394	44.0	4	97.0	52	2130	24.6	
395	32.0	4	135.0	84	2295	11.6	
396	28.0	4	120.0	79	2625	18.6	
397	31.0	4	119.0	82	2720	19.4	

	model_year	origin	name
0	70	1	chevrolet chevelle malibu
1	70	1	buick skylark 320
2	70	1	plymouth satellite
3	70	1	amc rebel sst
4	70	1	ford torino
..
393	82	1	ford mustang gl
394	82	2	vw pickup
395	82	1	dodge rampage
396	82	1	ford ranger
397	82	1	chevy s-10

```
[398 rows x 9 columns]
```

Prendiamo model_year come variabile categorica.

```
# Vediamo quindi le occorrenze di model_year
```

```
mpg["model_year"].value_counts()
```

```
model_year
```

```
73      40
```

```
78      36
```

```
76      34
```

```
82      31
```

```
75      30
```

```
70      29
```

```
79      29
```

```
80      29
```

```
81      29
```

```
71      28
```

```
72      28
```

```
77      28
```

```
74      27
```

```
Name: count, dtype: int64
```

```
# Quindi, nel 73 abbiamo avuto 40 auto vendute, nel 78 ne abbiamo  
vendute 36, etc
```

```
# Da quanto si vede, gli anni non sono in fila. Poichè questa è una  
variabile categorica, l'ordinamento
```

```
# non è importante. Comunque, dato che stiamo parlando di anni,  
conviene ordinarli dal più vecchio al più recente
```

```
mpg["model_year"].value_counts().sort_index()
```

```
model_year
```

```
70      29
```

```
71      28
```

```
72      28
```

```
73      40
```

```
74      27
```

```
75      30
```

```
76      34
```

```
77      28
```

```
78      36
```

```
79      29
```

```
80      29
```

```
81      29
```

```
82      31
Name: count, dtype: int64
```

```
# Vediamo quindi ora la funzione groupby. Essa mostrerà come le
variabili numeriche vengono raggruppate
# in base al valore di una variabile categorica.
```

```
mpg_group = mpg.groupby("model_year")
mpg_group
```

```
<pandas.core.groupby.generic.DataFrameGroupBy object at
0x000001F491CECAD0>
```

```
mpg_group.sum()
```

	mpg	cylinders	displacement \
model_year			
70	513.0	196	8161.0
71	595.0	156	5873.0
72	524.0	163	6114.5
73	684.0	255	10275.0
74	613.0	142	4637.0
75	608.0	168	6166.0
76	733.5	192	6725.0
77	654.5	153	5359.0
78	866.2	193	6401.0
79	727.7	169	5994.0
80	977.2	120	3359.0
81	879.7	134	3924.0
82	983.0	130	3995.0

	horsepower	weight
\		
model_year		
70	1301651501501401982202152251901701601502259595...	97811
71	889095?100105100881001651751531501801701751107...	83872
72	9580549086165175150153150208155160190971501301...	90656
73	1751501451371501981501581502152251751051001008...	136761
74	95?1001006780657510011010514015015014015083677...	77704
75	9510572721701451501481101051109511011012975831...	95304

76	8681927983140150120152100105819052607053100781...	104677
77	6880589670145110145130110105100981801701901497...	83926
78	4866527060110140139105958588100901058511012014...	103025
79	1158588901101301291381351551421251507165808077...	88605
80	7660706590889090789075927565105654848676767?67...	70663
81	848492110845864606765626863656574?757510074807...	73165
82	8888885849092?7468686370887570676767110859211...	76060

	acceleration	origin \
model_year		
70	375.5	38
71	424.0	40
72	423.5	43
73	572.5	55
74	437.5	45
75	481.5	44
76	542.0	50
77	432.2	44
78	569.0	58
79	458.6	37
80	491.1	64
81	472.9	57
82	515.8	51

	name
model_year	
70	chevrolet chevelle malibubuick skylark 320plym...
71	datsum pl510chevrolet vega 2300toyota coronafo...
72	toyota corona hardtopdodge colt hardtopvolkswa...
73	buick century 350amc matadorchevrolet malibufo...
74	plymouth dusterford maverickamc hornetchevrole...
75	plymouth valiant customchevrolet novamercury m...
76	fiat 131lopel 1900capri iidodge coltrenault 12t...
77	honda accord cvccbuick opel isuzu deluxerenaul...
78	volkswagen rabbit custom dieselford fiestamazd...
79	pontiac lemans v6mercury zephyr 6ford fairmont...
80	vw rabbittoyota corolla tercelchevrolet chevet...
81	plymouth reliantbuick skylarkdodge aries wagon...
82	chevrolet cavalierchevrolet cavalier wagonchev...

```
# E' uscito fuori uno schifo. Questo perché abbiamo effettuato la
somma rispetto alla variabile categorica
# model_year sia delle variabili numeriche sia delle variabili
categorica. Quello che ci conviene fare
# e' prendere in considerazione solo le variabili numeriche. Come si
fa? Per prima cosa vediamo qual è il tipo
# delle variabili
```

```
mpg.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 398 entries, 0 to 397
Data columns (total 9 columns):
#   Column                Non-Null Count  Dtype
---  -
0   mpg                    398 non-null   float64
1   cylinders              398 non-null   int64
2   displacement          398 non-null   float64
3   horsepower             398 non-null   object
4   weight                 398 non-null   int64
5   acceleration           398 non-null   float64
6   model_year             398 non-null   int64
7   origin                 398 non-null   int64
8   name                   398 non-null   object
dtypes: float64(3), int64(4), object(2)
memory usage: 28.1+ KB
```

```
# A quanto pare non c'è bisogno di cambiare il tipo di alcune
variabili. Dobbiamo quindi prendere in
# considerazione le sole variabili numeriche. Per farlo:
```

```
mpg_group = mpg.groupby('model_year')
[mpg.select_dtypes(include='number').columns].sum()
mpg_group
```

	mpg	cylinders	displacement	weight	acceleration
model_year \					
model_year					
70	513.0	196	8161.0	97811	375.5
2030					
71	595.0	156	5873.0	83872	424.0
1988					
72	524.0	163	6114.5	90656	423.5
2016					
73	684.0	255	10275.0	136761	572.5
2920					

74	613.0	142	4637.0	77704	437.5
1998					
75	608.0	168	6166.0	95304	481.5
2250					
76	733.5	192	6725.0	104677	542.0
2584					
77	654.5	153	5359.0	83926	432.2
2156					
78	866.2	193	6401.0	103025	569.0
2808					
79	727.7	169	5994.0	88605	458.6
2291					
80	977.2	120	3359.0	70663	491.1
2320					
81	879.7	134	3924.0	73165	472.9
2349					
82	983.0	130	3995.0	76060	515.8
2542					

	origin
model_year	
70	38
71	40
72	43
73	55
74	45
75	44
76	50
77	44
78	58
79	37
80	64
81	57
82	51

Se fossimo interessati ad una sola variabile, ad esempio acceleration:

```
mpg.groupby('model_year').sum(["acceleration"])
```

	mpg	cylinders	displacement	weight	acceleration
origin					
model_year					
70	513.0	196	8161.0	97811	375.5
38					
71	595.0	156	5873.0	83872	424.0

40					
72	524.0	163	6114.5	90656	423.5
43					
73	684.0	255	10275.0	136761	572.5
55					
74	613.0	142	4637.0	77704	437.5
45					
75	608.0	168	6166.0	95304	481.5
44					
76	733.5	192	6725.0	104677	542.0
50					
77	654.5	153	5359.0	83926	432.2
44					
78	866.2	193	6401.0	103025	569.0
58					
79	727.7	169	5994.0	88605	458.6
37					
80	977.2	120	3359.0	70663	491.1
64					
81	879.7	134	3924.0	73165	472.9
57					
82	983.0	130	3995.0	76060	515.8
51					

Se volessimo raggruppare il dataframe rispetto a acceleration e cylinders.

```
mpg.groupby('model_year').sum(["acceleration","cylinders"])
```

	mpg	cylinders	displacement	weight	acceleration
origin					
model_year					
70	513.0	196	8161.0	97811	375.5
38					
71	595.0	156	5873.0	83872	424.0
40					
72	524.0	163	6114.5	90656	423.5
43					
73	684.0	255	10275.0	136761	572.5
55					
74	613.0	142	4637.0	77704	437.5
45					
75	608.0	168	6166.0	95304	481.5
44					
76	733.5	192	6725.0	104677	542.0
50					
77	654.5	153	5359.0	83926	432.2
44					
78	866.2	193	6401.0	103025	569.0

58					
79	727.7	169	5994.0	88605	458.6
37					
80	977.2	120	3359.0	70663	491.1
64					
81	879.7	134	3924.0	73165	472.9
57					
82	983.0	130	3995.0	76060	515.8
51					

Per valori uguali di acceleration, avremo valori di cylinders.

Possiamo anche raggruppare le singole variabili. Se, ad esempio, volessimo calcolare la media delle cilindrata per ogni anno:

```
cylinders_per_year = mpg.groupby('model_year')['cylinders'].mean()
cylinders_per_year
```

model_year

```
70    6.758621
71    5.571429
72    5.821429
73    6.375000
74    5.259259
75    5.600000
76    5.647059
77    5.464286
78    5.361111
79    5.827586
80    4.137931
81    4.620690
82    4.193548
```

Name: cylinders, dtype: float64

Possiamo considerare anche più di una variabile. Se, ad esempio, volessimo la media di cylinders e weight per anno:

```
cylinders_weight_per_year = mpg.groupby('model_year')
[['cylinders', 'weight', 'acceleration']].mean()
cylinders_weight_per_year
```

model_year	cylinders	weight	acceleration
70	6.758621	3372.793103	12.948276
71	5.571429	2995.428571	15.142857

72	5.821429	3237.714286	15.125000
73	6.375000	3419.025000	14.312500
74	5.259259	2877.925926	16.203704
75	5.600000	3176.800000	16.050000
76	5.647059	3078.735294	15.941176
77	5.464286	2997.357143	15.435714
78	5.361111	2861.805556	15.805556
79	5.827586	3055.344828	15.813793
80	4.137931	2436.655172	16.934483
81	4.620690	2522.931034	16.306897
82	4.193548	2453.548387	16.638710

*# Possiamo anche raggruppare rispetto a più di una colonna.
 # Supponiamo di voler calcolare la somma di cylinders e weight
 rispetto a
 # model_year e origin. In questo caso:*

```
a = mpg.groupby(['model_year', 'origin'])
[['cylinders', 'weight', 'acceleration']].mean()
a
```

model_year	origin	cylinders	weight	acceleration
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
71	1	6.200000	3401.600000	14.575000
	2	4.000000	2024.000000	16.750000
	3	4.000000	1936.000000	16.375000
72	1	6.888889	3682.666667	14.055556
	2	4.000000	2573.200000	18.700000
	3	3.800000	2300.400000	15.400000
73	1	7.241379	3821.448276	13.620690
	2	4.000000	2335.714286	16.428571
	3	4.250000	2397.250000	15.625000
74	1	6.266667	3503.333333	15.966667
	2	4.000000	2139.333333	15.333333
	3	4.000000	2053.000000	17.666667
75	1	6.400000	3533.200000	16.350000
	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
76	1	6.363636	3405.409091	15.786364
	2	4.250000	2611.000000	16.050000
	3	4.500000	2217.500000	16.575000
77	1	6.222222	3422.000000	15.238889
	2	4.000000	2138.750000	15.000000
	3	4.166667	2295.833333	16.316667

78	1	6.000000	3141.136364	15.545455
	2	4.833333	2691.666667	16.233333
	3	4.000000	2221.250000	16.200000
79	1	6.260870	3210.217391	15.243478
	2	4.250000	2693.750000	18.400000
	3	4.000000	1997.500000	17.200000
80	1	4.285714	2822.428571	16.800000
	2	4.111111	2348.000000	18.366667
	3	4.076923	2290.307692	16.015385
81	1	4.923077	2695.000000	16.053846
	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
82	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

```
# Consideriamo una delle colonne numeriche: Ad esempio, consideriamo
la colonna weight,
# Per valori uguali di model_year, avremo valori diversi di origin, e
per diversi valori di origin avremo
# valori diversi di weight. Questo sta a significare che tra il primo
livello di aggregazione (model_year)
# ed il secondo livello (origin) c'è un AND nascosto.
# Consideriamo quindi un valore di weight, ad esempio 2309.200000.
Questo ci dice che weight è pari
# a 2309.200000 quando (where!!!) model_year = 70 AND origin = 2!!.
```

```
# Se abbiamo più di un indice, avremo a che fare con un multiindex.
```

```
mpg.groupby(['model_year','origin'])
[['cylinders','weight','acceleration']].mean().index
```

```
MultiIndex([(70, 1),
            (70, 2),
            (70, 3),
            (71, 1),
            (71, 2),
            (71, 3),
            (72, 1),
            (72, 2),
            (72, 3),
            (73, 1),
            (73, 2),
            (73, 3),
            (74, 1),
            (74, 2),
            (74, 3),
```

```

(75, 1),
(75, 2),
(75, 3),
(76, 1),
(76, 2),
(76, 3),
(77, 1),
(77, 2),
(77, 3),
(78, 1),
(78, 2),
(78, 3),
(79, 1),
(79, 2),
(79, 3),
(80, 1),
(80, 2),
(80, 3),
(81, 1),
(81, 2),
(81, 3),
(82, 1),
(82, 2),
(82, 3)],
names=['model_year', 'origin'])

```

```
# CVD
```

```

# POSSIAMO ANCHE MOSTRARE UNA SOLA COLONNA CORRISPONDENTE AI NOSTRI
INDICI. AD ESEMPIO, CONSIDERIAMO LA
# SOLITA COLONNA WEIGHT.

```

```
mpg.groupby(['model_year', 'origin'])['weight'].mean()
```

model_year	origin	
70	1	3716.500000
	2	2309.200000
	3	2251.000000
71	1	3401.600000
	2	2024.000000
	3	1936.000000
72	1	3682.666667
	2	2573.200000
	3	2300.400000
73	1	3821.448276

	2	2335.714286
	3	2397.250000
74	1	3503.333333
	2	2139.333333
	3	2053.000000
75	1	3533.200000
	2	2571.166667
	3	2303.250000
76	1	3405.409091
	2	2611.000000
	3	2217.500000
77	1	3422.000000
	2	2138.750000
	3	2295.833333
78	1	3141.136364
	2	2691.666667
	3	2221.250000
79	1	3210.217391
	2	2693.750000
	3	1997.500000
80	1	2822.428571
	2	2348.000000
	3	2290.307692
81	1	2695.000000
	2	2725.000000
	3	2269.166667
82	1	2637.750000
	2	2055.000000
	3	2132.777778

Name: weight, dtype: float64

CALCOLO STATISTICHE DI BASE IN SEGUITO A RAGGRUPPAMENTO

```
mpg.groupby('model_year').describe().transpose()
```

model_year		70	71	72	73
mpg	count	29.000000	28.000000	28.000000	40.000000
	mean	17.689655	21.250000	18.714286	17.100000
	std	5.339231	6.591942	5.435529	4.700245
	min	9.000000	12.000000	11.000000	11.000000

	25%	14.000000	15.500000	13.750000	13.000000
	50%	16.000000	19.000000	18.500000	16.000000
	75%	22.000000	27.000000	23.000000	20.000000
	max	27.000000	35.000000	28.000000	29.000000
cylinders	count	29.000000	28.000000	28.000000	40.000000
	mean	6.758621	5.571429	5.821429	6.375000
	std	1.724926	1.665079	2.073708	1.807215
	min	4.000000	4.000000	3.000000	3.000000
	25%	6.000000	4.000000	4.000000	4.000000
	50%	8.000000	6.000000	4.000000	7.000000
	75%	8.000000	6.500000	8.000000	8.000000
	max	8.000000	8.000000	8.000000	8.000000
displacement	count	29.000000	28.000000	28.000000	40.000000
	mean	281.413793	209.750000	218.375000	256.875000
	std	124.421380	115.102410	123.781964	121.722085
	min	97.000000	71.000000	70.000000	68.000000
	25%	198.000000	97.750000	109.250000	121.750000
	50%	307.000000	228.500000	131.000000	276.000000
	75%	383.000000	273.000000	326.000000	350.250000
	max	455.000000	400.000000	429.000000	455.000000
weight	count	29.000000	28.000000	28.000000	40.000000
	mean	3372.793103	2995.428571	3237.714286	3419.025000
	std	852.868663	1061.830859	974.520960	974.809133
	min	1835.000000	1613.000000	2100.000000	1867.000000
	25%	2648.000000	2110.750000	2285.500000	2554.500000
	50%	3449.000000	2798.000000	2956.000000	3338.500000

	75%	4312.000000	3603.250000	4169.750000	4247.250000
	max	4732.000000	5140.000000	4633.000000	4997.000000
acceleration	count	29.000000	28.000000	28.000000	40.000000
	mean	12.948276	15.142857	15.125000	14.312500
	std	3.330982	2.666171	2.850032	2.754222
	min	8.000000	11.500000	11.000000	9.500000
	25%	10.000000	13.375000	13.375000	12.500000
	50%	12.500000	14.500000	14.500000	14.000000
	75%	15.000000	16.125000	16.625000	16.000000
	max	20.500000	20.500000	23.500000	21.000000
origin	count	29.000000	28.000000	28.000000	40.000000
	mean	1.310345	1.428571	1.535714	1.375000
	std	0.603765	0.741798	0.792658	0.667467
	min	1.000000	1.000000	1.000000	1.000000
	25%	1.000000	1.000000	1.000000	1.000000
	50%	1.000000	1.000000	1.000000	1.000000
	75%	1.000000	2.000000	2.000000	2.000000
	max	3.000000	3.000000	3.000000	3.000000
model_year		74	75	76	77
\mpg	count	27.000000	30.000000	34.000000	28.000000
	mean	22.703704	20.266667	21.573529	23.375000
	std	6.420010	4.940566	5.889297	6.675862
	min	13.000000	13.000000	13.000000	15.000000
	25%	16.000000	16.000000	16.750000	17.375000
	50%	24.000000	19.500000	21.000000	21.750000
	75%	27.000000	23.000000	26.375000	30.000000

	max	32.000000	33.000000	33.000000	36.000000
cylinders	count	27.000000	30.000000	34.000000	28.000000
	mean	5.259259	5.600000	5.647059	5.464286
	std	1.583390	1.522249	1.667558	1.815206
	min	4.000000	4.000000	4.000000	3.000000
	25%	4.000000	4.000000	4.000000	4.000000
	50%	4.000000	6.000000	6.000000	4.000000
	75%	6.000000	6.000000	7.500000	8.000000
	max	8.000000	8.000000	8.000000	8.000000
displacement	count	27.000000	30.000000	34.000000	28.000000
	mean	171.740741	205.533333	197.794118	191.392857
	std	92.601127	87.669730	94.422256	107.813742
	min	71.000000	90.000000	85.000000	79.000000
	25%	90.000000	121.000000	102.500000	97.750000
	50%	122.000000	228.000000	184.000000	143.000000
	75%	250.000000	250.000000	291.000000	270.500000
	max	350.000000	400.000000	351.000000	400.000000
weight	count	27.000000	30.000000	34.000000	28.000000
	mean	2877.925926	3176.800000	3078.735294	2997.357143
	std	949.308571	765.179781	821.371481	912.825902
	min	1649.000000	1795.000000	1795.000000	1825.000000
	25%	2116.500000	2676.750000	2228.750000	2135.000000
	50%	2489.000000	3098.500000	3171.500000	2747.500000
	75%	3622.500000	3662.250000	3803.750000	3925.000000
	max	4699.000000	4668.000000	4380.000000	4335.000000
acceleration	count	27.000000	30.000000	34.000000	28.000000

	mean	16.203704	16.050000	15.941176	15.435714
	std	1.688532	2.471737	2.801419	2.273391
	min	13.500000	11.500000	12.000000	11.100000
	25%	15.250000	14.125000	13.925000	14.000000
	50%	16.000000	16.000000	15.500000	15.650000
	75%	17.000000	17.375000	17.550000	16.925000
	max	21.000000	21.000000	22.200000	19.000000
origin	count	27.000000	30.000000	34.000000	28.000000
	mean	1.666667	1.466667	1.470588	1.571429
	std	0.832050	0.730297	0.706476	0.835711
	min	1.000000	1.000000	1.000000	1.000000
	25%	1.000000	1.000000	1.000000	1.000000
	50%	1.000000	1.000000	1.000000	1.000000
	75%	2.000000	2.000000	2.000000	2.000000
	max	3.000000	3.000000	3.000000	3.000000
model_year \		78	79	80	81
mpg	count	36.000000	29.000000	29.000000	29.000000
	mean	24.061111	25.093103	33.696552	30.334483
	std	6.898044	6.794217	7.037983	5.591465
	min	16.200000	15.500000	19.100000	17.600000
	25%	19.350000	19.200000	29.800000	26.600000
	50%	20.700000	23.900000	32.700000	31.600000
	75%	28.000000	31.800000	38.100000	34.400000
	max	43.100000	37.300000	46.600000	39.100000
cylinders	count	36.000000	29.000000	29.000000	29.000000

	mean	5.361111	5.827586	4.137931	4.620690
	std	1.495761	1.774199	0.580895	1.082781
	min	4.000000	4.000000	3.000000	4.000000
	25%	4.000000	4.000000	4.000000	4.000000
	50%	5.500000	6.000000	4.000000	4.000000
	75%	6.000000	8.000000	4.000000	6.000000
	max	8.000000	8.000000	6.000000	8.000000
displacement	count	36.000000	29.000000	29.000000	29.000000
	mean	177.805556	206.689655	115.827586	135.310345
	std	76.012713	96.307581	33.744914	58.387929
	min	78.000000	85.000000	70.000000	79.000000
	25%	115.500000	121.000000	90.000000	98.000000
	50%	159.500000	183.000000	107.000000	119.000000
	75%	231.000000	302.000000	140.000000	151.000000
	max	318.000000	360.000000	225.000000	350.000000
weight	count	36.000000	29.000000	29.000000	29.000000
	mean	2861.805556	3055.344828	2436.655172	2522.931034
	std	626.023907	747.881497	432.235491	533.600501
	min	1800.000000	1915.000000	1835.000000	1755.000000
	25%	2282.500000	2556.000000	2110.000000	2065.000000
	50%	2910.000000	3190.000000	2335.000000	2385.000000
	75%	3410.000000	3725.000000	2800.000000	2900.000000
	max	4080.000000	4360.000000	3381.000000	3725.000000
acceleration	count	36.000000	29.000000	29.000000	29.000000
	mean	15.805556	15.813793	16.934483	16.306897
	std	2.129915	2.952931	2.826694	2.192509

	min	11.200000	11.300000	11.400000	12.600000
	25%	14.475000	14.000000	15.100000	14.800000
	50%	15.750000	15.000000	16.500000	16.200000
	75%	16.825000	17.300000	18.700000	17.300000
	max	21.500000	24.800000	23.700000	20.700000
origin	count	36.000000	29.000000	29.000000	29.000000
	mean	1.611111	1.275862	2.206897	1.965517
	std	0.837608	0.591400	0.818505	0.944259
	min	1.000000	1.000000	1.000000	1.000000
	25%	1.000000	1.000000	2.000000	1.000000
	50%	1.000000	1.000000	2.000000	2.000000
	75%	2.000000	1.000000	3.000000	3.000000
	max	3.000000	3.000000	3.000000	3.000000
model_year		82			
mpg	count	31.000000			
	mean	31.709677			
	std	5.392548			
	min	22.000000			
	25%	27.000000			
	50%	32.000000			
	75%	36.000000			
	max	44.000000			
cylinders	count	31.000000			
	mean	4.193548			
	std	0.601074			
	min	4.000000			
	25%	4.000000			
	50%	4.000000			
	75%	4.000000			
	max	6.000000			
displacement	count	31.000000			
	mean	128.870968			
	std	39.352037			
	min	91.000000			
	25%	105.000000			
	50%	119.000000			
	75%	142.000000			

weight	max	262.000000
	count	31.000000
	mean	2453.548387
	std	354.276713
	min	1965.000000
	25%	2127.500000
	50%	2525.000000
	75%	2727.500000
	max	3035.000000
acceleration	count	31.000000
	mean	16.638710
	std	2.484844
	min	11.600000
	25%	14.850000
	50%	16.400000
	75%	18.000000
	max	24.600000
origin	count	31.000000
	mean	1.645161
	std	0.914636
	min	1.000000
	25%	1.000000
	50%	1.000000
	75%	3.000000
	max	3.000000

Questa tabella è super leggibile!!!

RIPARTIAMO DAL NOSTRO Df CON RAGGRUPPAMENTO:

```
a = mpg.groupby(['model_year', 'origin'])
[['cylinders', 'weight', 'acceleration']].mean()
a
```

model_year	origin	cylinders	weight	acceleration
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
71	1	6.200000	3401.600000	14.575000
	2	4.000000	2024.000000	16.750000
	3	4.000000	1936.000000	16.375000
72	1	6.888889	3682.666667	14.055556
	2	4.000000	2573.200000	18.700000
	3	3.800000	2300.400000	15.400000
73	1	7.241379	3821.448276	13.620690
	2	4.000000	2335.714286	16.428571
	3	4.250000	2397.250000	15.625000

74	1	6.266667	3503.333333	15.966667
	2	4.000000	2139.333333	15.333333
	3	4.000000	2053.000000	17.666667
75	1	6.400000	3533.200000	16.350000
	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
76	1	6.363636	3405.409091	15.786364
	2	4.250000	2611.000000	16.050000
	3	4.500000	2217.500000	16.575000
77	1	6.222222	3422.000000	15.238889
	2	4.000000	2138.750000	15.000000
	3	4.166667	2295.833333	16.316667
78	1	6.000000	3141.136364	15.545455
	2	4.833333	2691.666667	16.233333
	3	4.000000	2221.250000	16.200000
79	1	6.260870	3210.217391	15.243478
	2	4.250000	2693.750000	18.400000
	3	4.000000	1997.500000	17.200000
80	1	4.285714	2822.428571	16.800000
	2	4.111111	2348.000000	18.366667
	3	4.076923	2290.307692	16.015385
81	1	4.923077	2695.000000	16.053846
	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
82	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

ESTRAIAMO QUINDI IL NOME DELLE COLONNE INDICE:

```
a.index.names
```

```
FrozenList(['model_year', 'origin'])
```

POSSIAMO ANCHE ESTRARRE I VALORI CHE GLI INDICI POSSONO ASSUMERE:

```
a.index.levels
```

```
FrozenList([[70, 71, 72, 73, 74, 75, 76, 77, 78, 79, 80, 81, 82], [1, 2, 3]])
```

La prima lista indica i valori che la variabile categorica più esterna assume. La seconda riguarda la variabile categorica più interna.

RICORDA: SIA LA VARIABILE PIU ESTERNA SIA QUELLA PIU INTERNA DEVONO ESSERE CATEGORICHE!!!

A partire dalla variabile più esterna assunta come indice, possiamo estrarre l'indice più interno ed i valori corrispondenti tramite la funzione loc

```
a.loc[70]
```

	cylinders	weight	acceleration
origin			
1	7.636364	3716.5	11.977273
2	4.000000	2309.2	16.500000
3	4.000000	2251.0	14.750000

Possiamo anche ragionare con più anni

```
a.loc[[70,75,81]]
```

		cylinders	weight	acceleration
model_year	origin			
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
75	1	6.400000	3533.200000	16.350000
	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
81	1	4.923077	2695.000000	16.053846
	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333

*# Possiamo anche passare una tupla contenente il valore dell'indice più esterno e di quello più interno. In questo modo
otterremo una Series contenente i valori corrispondenti. Ripartendo da a:*

```
a
```

		cylinders	weight	acceleration
model_year	origin			
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
71	1	6.200000	3401.600000	14.575000
	2	4.000000	2024.000000	16.750000
	3	4.000000	1936.000000	16.375000
72	1	6.888889	3682.666667	14.055556

73	2	4.000000	2573.200000	18.700000
	3	3.800000	2300.400000	15.400000
	1	7.241379	3821.448276	13.620690
74	2	4.000000	2335.714286	16.428571
	3	4.250000	2397.250000	15.625000
	1	6.266667	3503.333333	15.966667
75	2	4.000000	2139.333333	15.333333
	3	4.000000	2053.000000	17.666667
	1	6.400000	3533.200000	16.350000
76	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
	1	6.363636	3405.409091	15.786364
77	2	4.250000	2611.000000	16.050000
	3	4.500000	2217.500000	16.575000
	1	6.222222	3422.000000	15.238889
78	2	4.000000	2138.750000	15.000000
	3	4.166667	2295.833333	16.316667
	1	6.000000	3141.136364	15.545455
79	2	4.833333	2691.666667	16.233333
	3	4.000000	2221.250000	16.200000
	1	6.260870	3210.217391	15.243478
80	2	4.250000	2693.750000	18.400000
	3	4.000000	1997.500000	17.200000
	1	4.285714	2822.428571	16.800000
81	2	4.111111	2348.000000	18.366667
	3	4.076923	2290.307692	16.015385
	1	4.923077	2695.000000	16.053846
82	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

```
a.loc[(79,3)]
```

```
cylinders      4.0
weight         1997.5
acceleration    17.2
Name: (79, 3), dtype: float64
```

```
# CVD
```

```
# Supponiamo ora di voler estrarre solo l'indice più interno
# desiderato. Ad esempio, supponiamo di voler avere
# i dati relativi ai valori di origin 1,2,3 relativi al model_year
# pari sa 80. Per farlo, si utilizza
# la funzione xs (Cross Section):
```

```
a.xs(key=80, level = "model_year")
```

	cylinders	weight	acceleration
origin			
1	4.285714	2822.428571	16.800000
2	4.111111	2348.000000	18.366667
3	4.076923	2290.307692	16.015385

```
# CVD
```

*# Supponeamo di ovler estrarre più di un level. Supponiamo, ad es, di voler estrarre i level 89,81,82 e i dati relativi.
In questo caso non possiamo utilizzare xs, ma loc:*

```
a.loc[[80,81,82]]
```

		cylinders	weight	acceleration
model_year	origin			
80	1	4.285714	2822.428571	16.800000
	2	4.111111	2348.000000	18.366667
	3	4.076923	2290.307692	16.015385
81	1	4.923077	2695.000000	16.053846
	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
82	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

Torniamo alla nostra tabella raggruppata:

```
a
```

		cylinders	weight	acceleration
model_year	origin			
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
71	1	6.200000	3401.600000	14.575000
	2	4.000000	2024.000000	16.750000
	3	4.000000	1936.000000	16.375000
72	1	6.888889	3682.666667	14.055556

73	2	4.000000	2573.200000	18.700000
	3	3.800000	2300.400000	15.400000
	1	7.241379	3821.448276	13.620690
74	2	4.000000	2335.714286	16.428571
	3	4.250000	2397.250000	15.625000
	1	6.266667	3503.333333	15.966667
75	2	4.000000	2139.333333	15.333333
	3	4.000000	2053.000000	17.666667
	1	6.400000	3533.200000	16.350000
76	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
	1	6.363636	3405.409091	15.786364
77	2	4.250000	2611.000000	16.050000
	3	4.500000	2217.500000	16.575000
	1	6.222222	3422.000000	15.238889
78	2	4.000000	2138.750000	15.000000
	3	4.166667	2295.833333	16.316667
	1	6.000000	3141.136364	15.545455
79	2	4.833333	2691.666667	16.233333
	3	4.000000	2221.250000	16.200000
	1	6.260870	3210.217391	15.243478
80	2	4.250000	2693.750000	18.400000
	3	4.000000	1997.500000	17.200000
	1	4.285714	2822.428571	16.800000
81	2	4.111111	2348.000000	18.366667
	3	4.076923	2290.307692	16.015385
	1	4.923077	2695.000000	16.053846
82	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

Supponiamo di voler estrarre i valori 3 relativi a origin PER TUTTI GLI ANNI.

*# Per farlo, possiamo utilizzare sempre la funzione xs,
ma il parametro level deve essere valorizzato con origin*

`a.xs(key=3, level="origin")`

	cylinders	weight	acceleration
model_year			
70	4.000000	2251.000000	14.750000
71	4.000000	1936.000000	16.375000
72	3.800000	2300.400000	15.400000
73	4.250000	2397.250000	15.625000
74	4.000000	2053.000000	17.666667

75	4.000000	2303.250000	16.000000
76	4.500000	2217.500000	16.575000
77	4.166667	2295.833333	16.316667
78	4.000000	2221.250000	16.200000
79	4.000000	1997.500000	17.200000
80	4.076923	2290.307692	16.015385
81	4.333333	2269.166667	16.183333
82	4.000000	2132.777778	15.833333

Ovviamente la colonna origin è stata eliminata

a

model_year	origin	cylinders	weight	acceleration
70	1	7.636364	3716.500000	11.977273
	2	4.000000	2309.200000	16.500000
	3	4.000000	2251.000000	14.750000
71	1	6.200000	3401.600000	14.575000
	2	4.000000	2024.000000	16.750000
	3	4.000000	1936.000000	16.375000
72	1	6.888889	3682.666667	14.055556
	2	4.000000	2573.200000	18.700000
	3	3.800000	2300.400000	15.400000
73	1	7.241379	3821.448276	13.620690
	2	4.000000	2335.714286	16.428571
	3	4.250000	2397.250000	15.625000
74	1	6.266667	3503.333333	15.966667
	2	4.000000	2139.333333	15.333333
	3	4.000000	2053.000000	17.666667
75	1	6.400000	3533.200000	16.350000
	2	4.000000	2571.166667	15.083333
	3	4.000000	2303.250000	16.000000
76	1	6.363636	3405.409091	15.786364
	2	4.250000	2611.000000	16.050000
	3	4.500000	2217.500000	16.575000
77	1	6.222222	3422.000000	15.238889
	2	4.000000	2138.750000	15.000000
	3	4.166667	2295.833333	16.316667
78	1	6.000000	3141.136364	15.545455
	2	4.833333	2691.666667	16.233333
	3	4.000000	2221.250000	16.200000
79	1	6.260870	3210.217391	15.243478
	2	4.250000	2693.750000	18.400000
	3	4.000000	1997.500000	17.200000
80	1	4.285714	2822.428571	16.800000
	2	4.111111	2348.000000	18.366667

	3	4.076923	2290.307692	16.015385
81	1	4.923077	2695.000000	16.053846
	2	4.500000	2725.000000	17.500000
	3	4.333333	2269.166667	16.183333
82	1	4.300000	2637.750000	16.670000
	2	4.000000	2055.000000	19.950000
	3	4.000000	2132.777778	15.833333

E se volessimo estrarre più di un valore di origin PER TUTTI GLI ANNI?

Supponiamo, ad esempio, di voler estrarre i dati relativi ai valori # 2 e 3 della colonna origin. Non conviene utilizzare xs.

Per prima cosa torniamo al dataframe di partenza:

mpg

	mpg	cylinders	displacement	horsepower	weight	acceleration	\
0	18.0	8	307.0	130	3504	12.0	
1	15.0	8	350.0	165	3693	11.5	
2	18.0	8	318.0	150	3436	11.0	
3	16.0	8	304.0	150	3433	12.0	
4	17.0	8	302.0	140	3449	10.5	
..	
393	27.0	4	140.0	86	2790	15.6	
394	44.0	4	97.0	52	2130	24.6	
395	32.0	4	135.0	84	2295	11.6	
396	28.0	4	120.0	79	2625	18.6	
397	31.0	4	119.0	82	2720	19.4	

	model_year	origin	name
0	70	1	chevrolet chevelle malibu
1	70	1	buick skylark 320
2	70	1	plymouth satellite
3	70	1	amc rebel sst
4	70	1	ford torino
..
393	82	1	ford mustang gl
394	82	2	vw pickup
395	82	1	dodge rampage
396	82	1	ford ranger
397	82	1	chevy s-10

[398 rows x 9 columns]

A questo punto filtriemo il Df per i valori 1 e 3 della colonna origin:

```
mask = (mpg["origin"] == 1) | (mpg["origin"] == 3) # Oppure
mpg["origin"].isin([1,3])
mpg = mpg[mask]
mpg
```

	mpg	cylinders	displacement	horsepower	weight	acceleration	\
0	18.0	8	307.0	130	3504	12.0	
1	15.0	8	350.0	165	3693	11.5	
2	18.0	8	318.0	150	3436	11.0	
3	16.0	8	304.0	150	3433	12.0	
4	17.0	8	302.0	140	3449	10.5	
..	
392	27.0	4	151.0	90	2950	17.3	
393	27.0	4	140.0	86	2790	15.6	
395	32.0	4	135.0	84	2295	11.6	
396	28.0	4	120.0	79	2625	18.6	
397	31.0	4	119.0	82	2720	19.4	

	model_year	origin	name
0	70	1	chevrolet chevelle malibu
1	70	1	buick skylark 320
2	70	1	plymouth satellite
3	70	1	amc rebel sst
4	70	1	ford torino
..
392	82	1	chevrolet camaro
393	82	1	ford mustang gl
395	82	1	dodge rampage
396	82	1	ford ranger
397	82	1	chevy s-10

```
[328 rows x 9 columns]
```

```
mpg["origin"].value_counts()
```

```
origin
1    249
3     79
Name: count, dtype: int64
```

```
# CVD.
```

```
# A questo punto possiamo fare la group by relativa a model_year ed a origin
```

```
mpg_grouped = mpg.groupby(["model_year", "origin"])
[mpg.select_dtypes(include='number').columns].sum()
mpg_grouped
```

		mpg	cylinders	displacement	weight
acceleration \ model_year	origin				
70 263.5	1	336.0	168	7412.0	81763
29.5	3	51.0	8	210.0	4502
71 291.5	1	362.0	124	5140.0	68032
65.5	3	118.0	16	353.0	7744
72 253.0	1	293.0	124	5062.5	66288
77.0	3	121.0	19	497.0	11502
73 395.0	1	436.0	210	9109.0	110822
62.5	3	80.0	17	431.0	9589
74 239.5	1	275.0	94	3541.0	52550
106.0	3	176.0	24	537.0	12318
75 327.0	1	351.0	128	5068.0	70664
64.0	3	110.0	16	441.0	9213
76 347.3	1	427.5	140	5367.0	74919
66.3	3	112.0	18	429.0	8870
77 274.3	1	373.0	112	4362.0	61596
97.9	3	164.5	25	603.0	13775
78 342.0	1	479.0	132	4786.0	69105
129.6	3	237.5	32	858.0	17770
79 350.6	1	540.0	144	5319.0	73835
34.4	3	65.9	8	171.0	3995
80 117.6	1	181.4	30	1061.0	19757

208.2	3	460.2	53	1360.0	29774
81	1	357.9	64	2143.0	35035
208.7	3	395.5	52	1290.0	27230
194.2	1	589.0	86	2859.0	52755
333.4	3	314.0	36	934.0	19195
142.5					

		model_year	origin
model_year	origin		
70	1	1540	22
	3	140	6
71	1	1420	20
	3	284	12
72	1	1296	18
	3	360	15
73	1	2117	29
	3	292	12
74	1	1110	15
	3	444	18
75	1	1500	20
	3	300	12
76	1	1672	22
	3	304	12
77	1	1386	18
	3	462	18
78	1	1716	22
	3	624	24
79	1	1817	23
	3	158	6
80	1	560	7
	3	1040	39
81	1	1053	13
	3	972	36
82	1	1640	20
	3	738	27

Ed ecco che i valori relativi ad origin sono 1 e 3, CVD

*# Possiamo anche invertire i nostri level. Possiamo quindi invertire
model_year e origin tramite swaplevel*

```
mpg_grouped.swaplevel()
```

		mpg	cylinders	displacement	weight
acceleration \ origin	model_year				
1 263.5	70	336.0	168	7412.0	81763
3 29.5	70	51.0	8	210.0	4502
1 291.5	71	362.0	124	5140.0	68032
3 65.5	71	118.0	16	353.0	7744
1 253.0	72	293.0	124	5062.5	66288
3 77.0	72	121.0	19	497.0	11502
1 395.0	73	436.0	210	9109.0	110822
3 62.5	73	80.0	17	431.0	9589
1 239.5	74	275.0	94	3541.0	52550
3 106.0	74	176.0	24	537.0	12318
1 327.0	75	351.0	128	5068.0	70664
3 64.0	75	110.0	16	441.0	9213
1 347.3	76	427.5	140	5367.0	74919
3 66.3	76	112.0	18	429.0	8870
1 274.3	77	373.0	112	4362.0	61596
3 97.9	77	164.5	25	603.0	13775
1 342.0	78	479.0	132	4786.0	69105
3 129.6	78	237.5	32	858.0	17770
1 350.6	79	540.0	144	5319.0	73835
3 34.4	79	65.9	8	171.0	3995
1 117.6	80	181.4	30	1061.0	19757

3	80	460.2	53	1360.0	29774
208.2					
1	81	357.9	64	2143.0	35035
208.7					
3	81	395.5	52	1290.0	27230
194.2					
1	82	589.0	86	2859.0	52755
333.4					
3	82	314.0	36	934.0	19195
142.5					

		model_year	origin
origin	model_year		
1	70	1540	22
3	70	140	6
1	71	1420	20
3	71	284	12
1	72	1296	18
3	72	360	15
1	73	2117	29
3	73	292	12
1	74	1110	15
3	74	444	18
1	75	1500	20
3	75	300	12
1	76	1672	22
3	76	304	12
1	77	1386	18
3	77	462	18
1	78	1716	22
3	78	624	24
1	79	1817	23
3	79	158	6
1	80	560	7
3	80	1040	39
1	81	1053	13
3	81	972	36
1	82	1640	20
3	82	738	27

mpg_grouped

		mpg	cylinders	displacement	weight
acceleration \	model_year origin				
70	1	336.0	168	7412.0	81763
263.5					

29.5	3	51.0	8	210.0	4502
71	1	362.0	124	5140.0	68032
291.5	3	118.0	16	353.0	7744
65.5	1	293.0	124	5062.5	66288
72	3	121.0	19	497.0	11502
253.0	1	436.0	210	9109.0	110822
73	3	80.0	17	431.0	9589
395.0	1	275.0	94	3541.0	52550
62.5	3	176.0	24	537.0	12318
74	1	351.0	128	5068.0	70664
239.5	3	110.0	16	441.0	9213
106.0	1	427.5	140	5367.0	74919
75	3	112.0	18	429.0	8870
327.0	1	373.0	112	4362.0	61596
64.0	3	164.5	25	603.0	13775
76	1	479.0	132	4786.0	69105
347.3	3	237.5	32	858.0	17770
66.3	1	540.0	144	5319.0	73835
77	3	65.9	8	171.0	3995
274.3	1	181.4	30	1061.0	19757
97.9	3	460.2	53	1360.0	29774
78	1	357.9	64	2143.0	35035
342.0	3	395.5	52	1290.0	27230
129.6	1	589.0	86	2859.0	52755
79	3	314.0	36	934.0	19195
350.6					
34.4					
80					
117.6					
208.2					
81					
208.7					
194.2					
82					
333.4					

142.5

		model_year	origin
model_year	origin		
70	1	1540	22
	3	140	6
71	1	1420	20
	3	284	12
72	1	1296	18
	3	360	15
73	1	2117	29
	3	292	12
74	1	1110	15
	3	444	18
75	1	1500	20
	3	300	12
76	1	1672	22
	3	304	12
77	1	1386	18
	3	462	18
78	1	1716	22
	3	624	24
79	1	1817	23
	3	158	6
80	1	560	7
	3	1040	39
81	1	1053	13
	3	972	36
82	1	1640	20
	3	738	27

Possiamo anche ordinare i valori di model_year in ordine decrescente

```
mpg_grouped.sort_index(level = "model_year", ascending = False )
```

		mpg	cylinders	displacement	weight
acceleration \ model_year	origin				
82	3	314.0	36	934.0	19195
142.5					
	1	589.0	86	2859.0	52755
333.4					
81	3	395.5	52	1290.0	27230
194.2					
	1	357.9	64	2143.0	35035
208.7					

80	3	460.2	53	1360.0	29774
208.2	1	181.4	30	1061.0	19757
117.6	3	65.9	8	171.0	3995
79	1	540.0	144	5319.0	73835
34.4	3	237.5	32	858.0	17770
350.6	1	479.0	132	4786.0	69105
78	3	164.5	25	603.0	13775
129.6	1	373.0	112	4362.0	61596
342.0	3	112.0	18	429.0	8870
77	1	427.5	140	5367.0	74919
97.9	3	110.0	16	441.0	9213
274.3	1	351.0	128	5068.0	70664
76	3	176.0	24	537.0	12318
66.3	1	275.0	94	3541.0	52550
347.3	3	80.0	17	431.0	9589
75	1	436.0	210	9109.0	110822
64.0	3	121.0	19	497.0	11502
327.0	1	293.0	124	5062.5	66288
74	3	118.0	16	353.0	7744
106.0	1	362.0	124	5140.0	68032
239.5	3	51.0	8	210.0	4502
73	1	336.0	168	7412.0	81763
62.5					
395.0					
72					
77.0					
253.0					
71					
65.5					
291.5					
70					
29.5					
263.5					
		model_year	origin		
model_year	origin				
82	3	738	27		
	1	1640	20		

81	3	972	36
	1	1053	13
80	3	1040	39
	1	560	7
79	3	158	6
	1	1817	23
78	3	624	24
	1	1716	22
77	3	462	18
	1	1386	18
76	3	304	12
	1	1672	22
75	3	300	12
	1	1500	20
74	3	444	18
	1	1110	15
73	3	292	12
	1	2117	29
72	3	360	15
	1	1296	18
71	3	284	12
	1	1420	20
70	3	140	6
	1	1540	22

Se invece effettuassimo l'ordinamento per origin, otterremo dei duplicati nella colonna model_year

```
mpg_grouped.sort_index(level = "origin", ascending = False )
```

		mpg	cylinders	displacement	weight
acceleration \ model_year	origin				
82 142.5	3	314.0	36	934.0	19195
81 194.2	3	395.5	52	1290.0	27230
80 208.2	3	460.2	53	1360.0	29774
79 34.4	3	65.9	8	171.0	3995
78 129.6	3	237.5	32	858.0	17770
77 97.9	3	164.5	25	603.0	13775
76	3	112.0	18	429.0	8870

66.3					
75	3	110.0	16	441.0	9213
64.0					
74	3	176.0	24	537.0	12318
106.0					
73	3	80.0	17	431.0	9589
62.5					
72	3	121.0	19	497.0	11502
77.0					
71	3	118.0	16	353.0	7744
65.5					
70	3	51.0	8	210.0	4502
29.5					
82	1	589.0	86	2859.0	52755
333.4					
81	1	357.9	64	2143.0	35035
208.7					
80	1	181.4	30	1061.0	19757
117.6					
79	1	540.0	144	5319.0	73835
350.6					
78	1	479.0	132	4786.0	69105
342.0					
77	1	373.0	112	4362.0	61596
274.3					
76	1	427.5	140	5367.0	74919
347.3					
75	1	351.0	128	5068.0	70664
327.0					
74	1	275.0	94	3541.0	52550
239.5					
73	1	436.0	210	9109.0	110822
395.0					
72	1	293.0	124	5062.5	66288
253.0					
71	1	362.0	124	5140.0	68032
291.5					
70	1	336.0	168	7412.0	81763
263.5					

		model_year	origin
model_year	origin		
82	3	738	27
81	3	972	36
80	3	1040	39
79	3	158	6
78	3	624	24
77	3	462	18
76	3	304	12

75	3	300	12
74	3	444	18
73	3	292	12
72	3	360	15
71	3	284	12
70	3	140	6
82	1	1640	20
81	1	1053	13
80	1	560	7
79	1	1817	23
78	1	1716	22
77	1	1386	18
76	1	1672	22
75	1	1500	20
74	1	1110	15
73	1	2117	29
72	1	1296	18
71	1	1420	20
70	1	1540	22

CVD

Torniamo al nostro df iniziale

mpg.head()

	mpg	cylinders	displacement	horsepower	weight	acceleration
0	18.0	8	307.0	130	3504	12.0
1	15.0	8	350.0	165	3693	11.5
2	18.0	8	318.0	150	3436	11.0
3	16.0	8	304.0	150	3433	12.0
4	17.0	8	302.0	140	3449	10.5

	origin	name
0	1	chevrolet chevelle malibu
1	1	buick skylark 320
2	1	plymouth satellite
3	1	amc rebel sst
4	1	ford torino

```
# Statistiche di base, metodo ARG-
```

```
# Finora abbiamo calcolato le statistiche di base per singola colonna.  
# Possiamo calcolare più velocemente le statistiche di base tramite la  
funzione AGG.
```

```
# Per prima cosa, però, dobbiamo estrarre dal nostro Df SOLO le  
colonne numeriche
```

```
df_numeriche = mpg.select_dtypes(include=['number'])  
df_numeriche
```

	mpg	cylinders	displacement	weight	acceleration	model_year
origin						
0	18.0	8	307.0	3504	12.0	70
1						
1	15.0	8	350.0	3693	11.5	70
1						
2	18.0	8	318.0	3436	11.0	70
1						
3	16.0	8	304.0	3433	12.0	70
1						
4	17.0	8	302.0	3449	10.5	70
1						
..
...						
392	27.0	4	151.0	2950	17.3	82
1						
393	27.0	4	140.0	2790	15.6	82
1						
395	32.0	4	135.0	2295	11.6	82
1						
396	28.0	4	120.0	2625	18.6	82
1						
397	31.0	4	119.0	2720	19.4	82
1						

```
[328 rows x 7 columns]
```

```
df_numeriche.agg(["std", "mean"]).transpose()
```

	std	mean
mpg	7.723398	22.580488
cylinders	1.738563	5.731707
displacement	106.050898	211.413110
weight	861.527429	3087.189024
acceleration	2.624770	15.307927

model_year	3.748239	76.051829
origin	0.856510	1.481707

*# Ovviamente ha poco senso effettuare media e ev std per alcune di queste colonne. Il tutto è solo a titolo di esempio.
Se volessimo selezionare solo alcune colonne, tipo weight e acceleration, possiamo filtrare il Df
precedente per queste due variabili*

```
df_numeriche.agg(["std","mean"])\n[["weight","acceleration"]].transpose()
```

	std	mean
weight	861.527429	3087.189024
acceleration	2.624770	15.307927

Oppure, possiamo passare un dizionario nella nostra funzione agg

```
df_numeriche.agg({"weight":["std","mean"],"acceleration":\n["std","mean"]}).transpose()
```

	std	mean
weight	861.527429	3087.189024
acceleration	2.624770	15.307927